МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
им. Н.Э. Баумана

Факультет «Информатика и системы управления»
Кафедра «Систем обработки информации и управления»

ОТЧЕТ

Лабораторная работа №4
по дисциплине «Методы машинного обучения»

Тема: «Алгоритм Policy Iteration»
Cliff Walking

ИСПОЛНИТЕЛЬ: ___Очеретная С.В.__
ФИО
группа ИУ5-25М _____
подпись
"__"_____2024 г.

ПРЕПОДАВАТЕЛЬ: _____Гапанюк Ю.Е.____
ФИО
_____
подпись
"__"_____2024 г.

Москва - 2024

Цель лабораторной работы: ознакомление с базовыми методами обучения с подкреплением.

Задание

На основе рассмотренного на лекции примера реализуйте алгоритм Policy Iteration для любой среды обучения с подкреплением (кроме рассмотренной на лекции среды Toy Text / Frozen Lake) из библиотеки Gym (или аналогичной библиотеки).

Ход работы

1. Подготовка

Создали виртуальное окружение:

```
python -m venv env
```

Перешли в него:

```
env/Scripts/activate.
```

Установили зависимости:

```
pip install -r .\examples\requirements.txt
```

2. Описание среды

Будем работать со средой Cliff Walking:

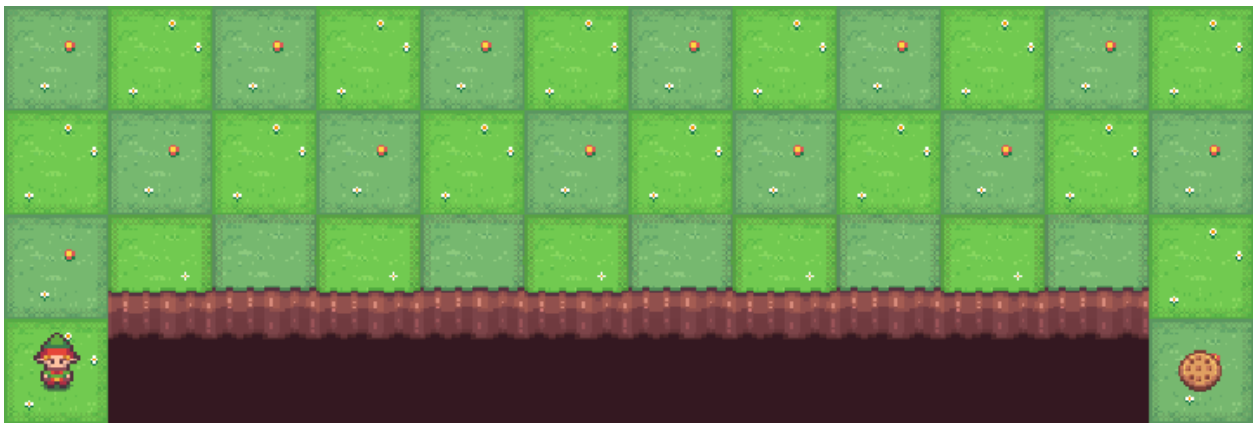

Поле представляет собой матрицу 4x12. Агент начинает проходить карту с ячейки [3, 0] (левый нижний угол). Ему необходимо достичь ячейки [3, 11], т.е. цель размещена в правом нижнем углу. Также агенту нельзя

наступать на обрыв – это ячейки [3, 1...10] (внизу, по центру). Если агент наступит на обрыв, он вернется к началу. Эпизод заканчивается, когда агент достигает цели.

Агент может совершить 4 действия:

0: переместиться вверх;

1: передвинуться вправо;

2: передвинуться вниз;

3: передвинуться влево.

За каждый шаг полагается -1 награда, а за шаг в обрыв — -100.

Выведем информацию о наборе с помощью следующего кода:

```
state, action = 0, 0
env = gym.make("CliffWalking-v0")
print('Пространство состояний:')
pprint(env.observation_space)
print()
print('Пространство действий:')
pprint(env.action_space)
print()
print('Вероятности для 0 состояния:')
pprint(env.P[state])
print(‘Вероятности для 46го состояния:')
pprint(env.P[46])
```

Вывод:

```
(env) PS C:\Users\Mi\my_documents\master_program\sem2\MMO\lab4> python .\cliff_walking_info.py
Пространство состояний:
Discrete(48)

Пространство действий:
Discrete(4)

Вероятности для 0 состояния:
{0: [(1.0, 0, -1, False)],
 1: [(1.0, 1, -1, False)],
 2: [(1.0, 12, -1, False)],
 3: [(1.0, 0, -1, False)]}
Вероятности для 34го состояния:
{0: [(1.0, 22, -1, False)],
 1: [(1.0, 35, -1, False)],
 2: [(1.0, 36, -100, False)],
 3: [(1.0, 33, -1, False)]}
Вероятности для 35го состояния:
{0: [(1.0, 23, -1, False)],
 1: [(1.0, 35, -1, False)],
 2: [(1.0, 47, -1, True)],
 3: [(1.0, 34, -1, False)]}
```

В итоге получаем: размерность пространства состояний 48 (это размерность поля 4x12), пространства действий 4 (вверх, право, вниз, влево).

Также в качестве примера просмотрели нулевое, 34ое и 35ое состояния из матрицы состояний env.P. Матрица env.P состоит из 48 строк (состояния от 0го до 47). Каждая строка состоит из объекта с 4мя действиями. Для каждого действия указан массив возможных состояний, в которое можно перейти из текущего состояния. Значение флага в конце массива равное True означает достижение цели. Формат строки:

```
{action: [(probability, nextstate, reward, done)]}
```

Таким образом, находясь в нулевом состоянии:

– можем остаться в нем при действиях 0 (вверх) и 3 (влево), т.к. врежемся в стенку карты;
– можем переместиться в состояние 1 при действии 1 (вправо);
– можем переместиться в состояние 12 при действии 2 (вниз);

Находясь в 34ом состоянии:

– переместимся в другое состояние при действиях 0, 1, 3;
– попадем в обрыв (-100 к награде) при действии 2 (вниз).

Находясь в 35ом состоянии:

- останемся в 35ом при действии 1 (вправо);
- переместимся в другое состояние при действиях 0, 3;
- достигнем цели (состояния 37) – флаг done=True

3. Реализация алгоритма

Произведем обучение с подкреплением для нашей модели. Для этого реализуем класс PolicyIterationAgent, эмулирующий работу агента.

Инициализируем класс, задав пространство состояний (observation_dim = 48), действия (0-3), политику попыток (25%, что выполнится одно из 4ех действий), начальные значения состояний (state_values), максимальное число итераций (10000) и начальные значения параметров theta, gamma:

```
def __init__(self, env):
     self.env = env
     self.observation_dim = 48
     self.actions_variants = np.array([0,1,2,3])
     self.policy_probs = np.full((self.observation_dim,
len(self.actions_variants)), 0.25)
     self.state_values = np.zeros(shape=(self.observation_dim))
     self.maxNumberOfIterations = 10000
     self.theta=1e-6
     self.gamma=0.99
```

Также добавим в класс метод вывода политики:

```
def print_policy(self):
     print('Стратегия:')
     pprint(self.policy_probs)
```

Метод оценивания стратегии:

```
def policy_evaluation(self):
    valueFunctionVector = self.state_values
    for iterations in range(self.maxNumberOfIterations):
        valueFunctionVectorNextIteration=np.zeros(shape=(self.ob
servation_dim))
        for state in range(self.observation_dim):
            action_probabilities = self.policy_probs[state]
            outerSum=0
            for action, prob in enumerate(action_probabilities):
```

```
                innerSum=0
                for probability, next_state, reward,
isTerminalState in self.env.P[state][action]:
                    innerSum=innerSum+probability*(reward+self.g
amma*self.state_values[next_state])
                outerSum=outerSum+self.policy_probs[state][actio
n]*innerSum
            valueFunctionVectorNextIteration[state]=outerSum
        if(np.max(np.abs(valueFunctionVectorNextIteration-
valueFunctionVector))<self.theta):
            valueFunctionVector=valueFunctionVectorNextIteration
            break
        valueFunctionVector=valueFunctionVectorNextIteration
    return valueFunctionVector
```

Метод для улучшения стратегии:

```
def policy_improvement(self):
    qvaluesMatrix=np.zeros((self.observation_dim,
len(self.actions_variants)))
    improvedPolicy=np.zeros((self.observation_dim,
len(self.actions_variants)))
    for state in range(self.observation_dim):
        for action in range(len(self.actions_variants)):
            for probability, next_state, reward, isTerminalState
in self.env.P[state][action]:
                qvaluesMatrix[state,action]=qvaluesMatrix[state,
action]+probability*(reward+self.gamma*self.state_values[next_st
ate])

        bestActionIndex=np.where(qvaluesMatrix[state,:]==np.max(
qvaluesMatrix[state,:]))
        improvedPolicy[state,bestActionIndex]=1/np.size(bestActi
onIndex)
    return improvedPolicy
```

Реализация алгоритма:

```
def policy_iteration(self, cnt):
    policy_stable = False
    for i in range(1, cnt+1):
        self.state_values = self.policy_evaluation()
        self.policy_probs = self.policy_improvement()
    print(f'Алгоритм выполнился за {i} шагов.')
```

Проигрывание сцены:

```
def play_agent(agent):
env2 = gym.make('CliffWalking-v0', render_mode='human')
state = env2.reset()[0]
done = False
while not done:
    p = agent.policy_probs[state]
    if isinstance(p, np.ndarray):
        action = np.random.choice(len(agent.actions_variants),
p=p)
    else:
        action = p
    next_state, reward, terminated, truncated, _ =
env2.step(action)
    env2.render()
    state = next_state
    if terminated or truncated:
        done = True
```

Теперь создадим основную функцию для выполнения и запустим скрипт:

```
def main():
    # Создание среды
    env = gym.make('FrozenLake-v1')
    env.reset()
    # Обучение агента
    agent = PolicyIterationAgent(env)
    agent.print_policy()
    agent.policy_iteration(10000)
    agent.print_policy()
    # Проигрывание сцены для обученного агента
    play_agent(agent)
```

Наш агент долго блуждал по карте, но в итоге достиг цели. Получили следующий массив стратегии

```
Стратегия:
array([[0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
```

```
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.33333333, 0.33333333, 0.        , 0.33333333],
       [0.25      , 0.25      , 0.25      , 0.25      ],
       [0.33333333, 0.        , 0.33333333, 0.33333333],
       [0.5       , 0.        , 0.        , 0.5       ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [1.        , 0.        , 0.        , 0.        ],
       [0.5       , 0.5       , 0.        , 0.        ],
       [0.33333333, 0.33333333, 0.33333333, 0.        ]])
Размер массива стратегии:
48
```

Данный массив представляет собой матрицу состояний обученного агента. Каждая строка – массив вероятностей 1го действия (чем больше вероятность, тем лучше выполнение конкретного действия по мнению обученного агента). Как видим по матрице – для состояний 0-24,35 массивы с одинаковыми значениями 0,25, поскольку при перемещениях из верхних ячеек (и 24ой, 35ой) ничего не происходит. Для состояний 25-34 агент понял, что не выгодно двигаться вниз (для действия 0 – вероятность 0, а для

остальных 0,33). При 36ом состоянии невыгодно двигаться вправо (второе значения массива – 0, остальные 0,33). Находясь в обрыве (хотя это невозможно) в состоянии 37 – нужно двигаться влево или вверх, в состояниях 38-45 – только вверх, в состоянии 46 – вправо или вверх. Находясь в состоянии 47, нужно не двигаться влево (в обрыв).